

## Definição & Exemplos

---

Na regressão linear, utilizamos variáveis explicativas para tentar prever uma variável resposta, ambas tendo valores contínuos. Já a regressão logística é aplicada quando queremos atribuir um rótulo a partir de valores, sendo esses contínuos ou não. Por exemplo, em um hospital poderíamos ter pacientes com o rótulo “doente” ou “não doente” baseando-se em atributos como temperatura corporal e pressão sanguínea.

- variável resposta  $y$  - rótulo previsto;
- variável(is) explicativa(s)  $X$  - atributo(s) previsor(es).

Em outras palavras, na regressão logística, calcularemos a probabilidade de um indivíduo pertencer a uma classe ou não a partir de um ou mais valores apresentados, de forma a realizarmos uma classificação binária.




Figura 1<sup>1</sup>: Tentativa de classificação por regressão logística (esquerda) e regressão linear (direita).

Para estimar os valores na regressão, utilizamos a seguinte equação:

$$y = b_0 + b_1 * x_1 \rightarrow y = a * x + b$$

onde  $y$  é o atributo que queremos prever,  $b_0$  é uma constante angular,  $b_1$  é um coeficiente e  $x_1$  é a variável explicativa em questão. Perceba que na regressão logística a nossa reta sofre um “achatamento” para que ela retorne apenas valores entre 0 e 1. Dessa forma, para que tenhamos como resultado um valor que represente uma probabilidade, o valor de  $y$  será passado para outra função, a qual é chamada de função logística ou sigmóide.

Suponhamos que haja uma base de crédito com os seguintes atributos previsores:

- Histórico de pagamento = Bom (0)
- Dívida = Média (0)
- Garantias = Nenhuma (1)
- Renda anual => 30 (2)

Vamos elencar coeficientes  $b_{ii}$  para cada atributo. Nesse caso, temos que:

---

<sup>1</sup> Fonte: <https://matheusfacure.github.io/2017/02/25/regr-log/>

- $b_0 = -0,12$
- $b_1 = -0,71$
- $b_2 = 0,24$
- $b_3 = \text{Garantias} = -0,54$
- $b_4 = \text{Renda anual} = 1,07$

Calculando  $y$ , obtemos:

$$y = -0,12 + (b_1 * \text{Histórico de pagamento}) + (b_2 * \text{Dívida}) + (b_3 * \text{Garantias}) + (b_4 * \text{Renda anual})$$

$$y = -0,12 + (-0,71 * 0) + (0,24 * 0) + (-0,54 * 1) + (1,07 * 2)$$

$$y = 1,48$$

Agora, usaremos  $y$  como entrada para a função sigmoid. Logo,

$$f(y) = \frac{1}{1 + e^{-y}}$$

$$f(1,48) = \frac{1}{1 + e^{-1,48}}$$

$$f(1,48) = 0,8145$$

Portanto, o usuário com esse perfil teria 81% de probabilidade de pagar determinado empréstimo.





Figura 2<sup>2</sup>: Função sigmoid ou logística

---

<sup>2</sup> A função sigmoid é utilizada em redes neurais em problemas de classificação binária.

## Exemplo gráfico & Cálculo do erro

---



*Figura 3: Probabilidade de passar no exame a partir das horas de estudo.*

Pelo gráfico, podemos perceber que quanto mais uma pessoa estuda para um exame, ela tem uma probabilidade maior de passar.

Pelo fato de estarmos trabalhando em um problema de classificação, a função MSE (Mean Squared Error) não será mais útil, pois os resíduos não serão mais medidos em termos de distância. Tendo isso em vista, utilizaremos a função de custo chamada Binary Cross Entropy.

$$L = - \sum_i y_i \log \tilde{y}_i + (1 - y_i) \log (1 - \tilde{y}_i)$$